


Fashion MNIST & Data Augmentation

Hur varierad träningsdata påverkar en CNN-modells förmåga att känna igen klädesplagg.



Kort kontext: data och preprocessing

60 000

träningsbilder

10 000

testbilder

28×28


gråskala

10

klasser

Vad gjorde preprocessing?

- Laddade Fashion MNIST från Keras
- Skalade pixelvärden från 0-255 till 0-1
- Formade bilderna till (28, 28, 1) för CNN
- Kontrollerade att klasserna är balanserade




Real life: först förbereder vi materialet rätt, sedan kan modellen börja lära sig.

Baseline: vår startpunkt och första problem

CNN-modellen

Input 28×28×1
Conv2D + ReLU
MaxPooling
Conv2D + ReLU
MaxPooling
Flatten
Dense 10 + Softmax

**89.3%**

test accuracy

96%

train accuracy

90%

validation accuracy

+6%

gap

Overfitting: modellen blev mycket bättre på träningsbilderna än på valideringsbilderna. Det är som en elev som memorerar gamla frågor istället för att förstå ämnet.

Vad är data augmentation?

Data augmentation betyder att vi skapar små, realistiska variationer av träningsbilderna under träningen.

Rotation

Bilden blir lite sned. Plagget är fortfarande samma klass.

Zoom

Bilden blir lite större eller mindre. Modellen lär sig storleksvariation.

Shift

Bilden flyttas lite åt sidan, upp eller ner. Objektet behöver inte ligga exakt i mitten.

Viktigt: augmentation används bara på träningsdata - inte på validation eller testdata.


Real life: vi tränar inte någon med bara perfekta bilder. Vi visar också lite sneda och förflyttade exempel.

Varför behövs augmentation?

Problemet

Om modellen bara ser perfekta träningsbilder kan den bli för beroende av exakt position, storlek och form.

Shift 10%




En sko är fortfarande en sko, även om den flyttas lite.

Idén

Vi gör träningen lite svårare och mer varierad, så modellen måste lära sig mer generella mönster.

Rotation 5%



En bild är fortfarande samma klass, även om den roteras lite.

Målet är inte att göra bilderna konstiga - målet är realistisk variation.

Vad testade vi?

Samma CNN i alla experiment. Bara augmentation-lagret ändrades.

Experiment	Augmentation	Test acc.	Gap	Kort tolkning
Baseline	Ingen	89.32%	+6.0%	Referens
Rotation 5%	RandomRotation(0.05)	89.42%	+1.2%	Mindre gap
Zoom 10%	RandomZoom(0.10)	89.82%	+3.7%	Lite bättre acc.
Shift 10%	RandomTranslation(0.10, 0.10)	90.35%	-0.6%	Bäst
Mild komb.	Rotation + zoom + shift	87.22%	-0.7%	Bra gap, lägre acc.
Stark komb.	Starkare nivåer	78.37%	+5.1%	För starkt


Experimenttänk: vi ändrade en sak i taget, annars vet vi inte vad som gav resultatet.

Hur ser augmentation ut?

Här ser man hur träningsbilderna får små variationer. Klassen ändras inte.


Rotation 5%

Rotation 5%




Zoom 10%

Zoom 10%



Shift 10%

Shift 10%




Det här är huvudidén: fler realistiska exempel utan att samla in nya bilder.

Hur tränade modellerna?

Validation accuracy och validation loss över tid för alla experiment.

Valideringskurvor – alla experiment vs baseline




Inte bara slutresultat

Shift var stabil

Stark var för mycket

Vi ser hur modellerna lär sig - inte bara slutbetyget.

Resultat: vilken variant gav bäst accuracy?



Vad ser vi?

- Shift 10% blev bäst: cirka 90.35%
- Zoom och rotation låg nära baseline
- Stark kombination blev tydligt sämre
- För mycket förändring kan ta bort viktig information


Accuracy visar slutresultatet, men inte hela träningsbeteendet. Därför behövde vi slide 8 också.

Resultat: overfitting-gap

Gap = train accuracy minus validation accuracy. Mindre gap betyder ofta bättre generalisering.

Tolkning

- Baseline hade störst gap
- Rotation minskade gapet mycket
- Shift och mild kombination fick negativt gap
- Det betyder att träningsdelen blev svårare än valideringen



Det här är ett tecken på att augmentation kan göra modellen mer robust.

Slutsatser och begränsningar

1. Lagom hjälpte

Shift 10% gav bäst resultat och bättre generalisering.

2. För starkt skadar

Stark kombination gjorde bilderna för förändrade.

3. Kurvor behövs

Accuracy räcker inte. Vi måste också se träningen över tid.

Begränsningar

- Fashion MNIST är bara 28×28 pixlar
- Vissa klasser liknar varandra mycket
- Vi körde 10 epoker
- Resultat kan variera mellan körningar

Nästa steg

- Testa EarlyStopping
- Testa Dropout eller regularisering
- Testa fler augmentation-nivåer stegvis
- Köra flera repetitioner och ta medelvärde

Det viktigaste: vi kan förklara vad vi ändrade, varför vi gjorde det och varför resultaten blev som de blev.

Tack för oss!

Frågor?

